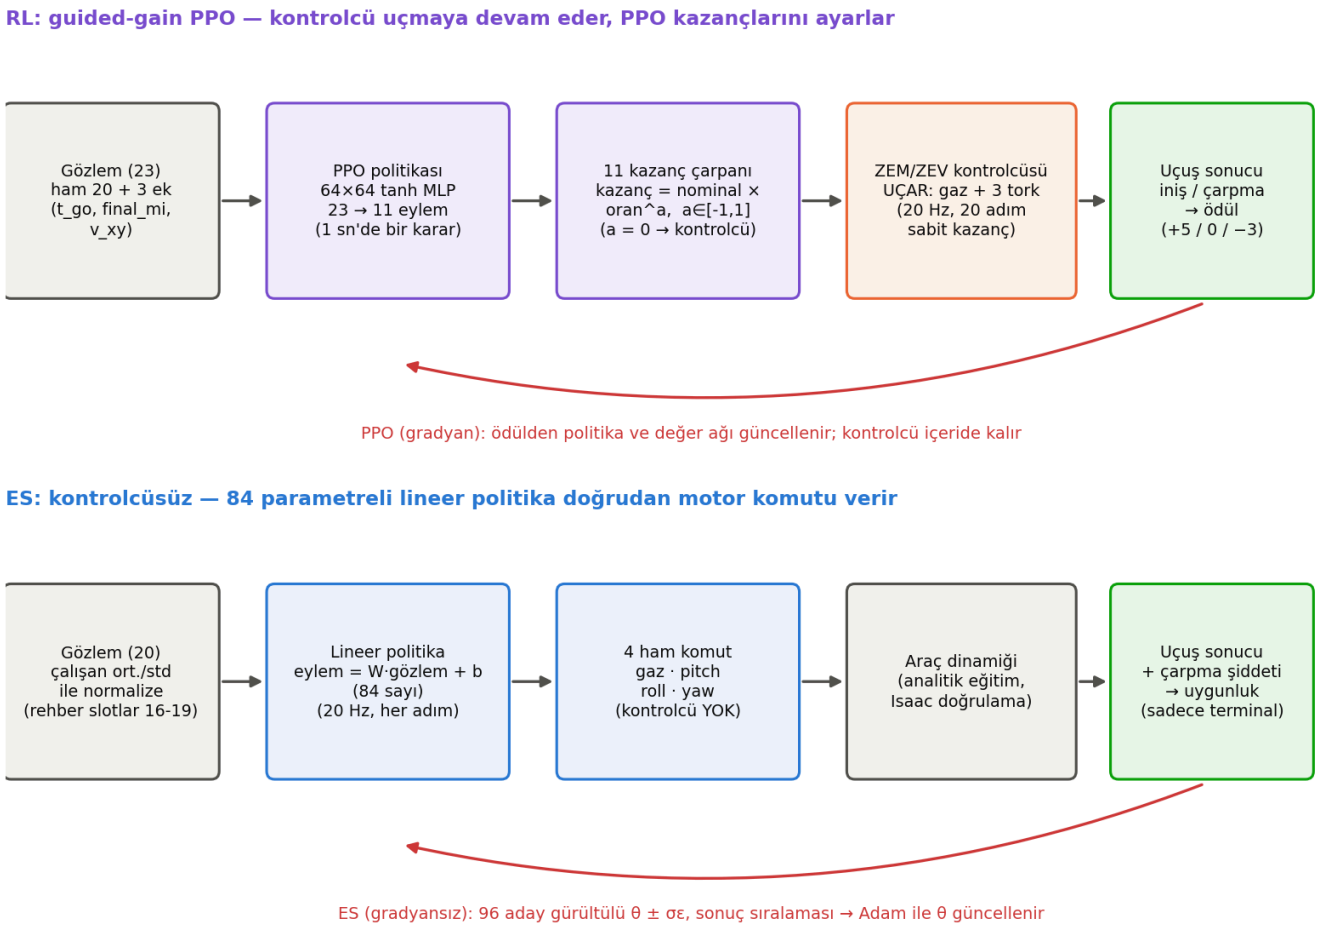
RL (guided-gain PPO) ve evrimsel strateji (ES): aynı iniş görevinde karşılaştırma

LunarSim · Apollo LM · Isaac orbit_descent (200 m, 10–30 m/s yanal hız) · tüm sayılar `out/` ve `~/lunarsim_artifacts/` dosyalarından okunmuştur

%52.6	%89.6	%91.1	20–17
ZEM/ZEV kontrolcüsü 101/192 · GA [45.6, 59.5]	RL: guided-gain PPO 172/192 · GA [84.5, 93.2]	ES (kontrolcüsüz) 175/192 · GA [86.3, 94.4]	ES-only – PPO-only McNemar p = 0.74

Özet. İki yöntem de kontrolcüyü anlamlı biçimde geçiyor (PPO 72–1, p=1.6e-20; ES 79–5, p=3.4e-18). **ES ile PPO arasında istatistiksel fark yok**: ES 175/192, PPO 172/192; eşleştirilmiş farkın (ES − PPO) dalga-bloku bootstrap %95 aralığı [-3.6, +6.2] puan, dalgaların 11/16'inde ES ≥ PPO (8 dalgada ES, 5 dalgada PPO önde). Bu bir "ES PPO'dan iyi" iddiası *değildir*. Kontrolcü vektörleri iki dosyada bölüm bölüm birebir aynıdır (aynı tohum, aynı başlangıçlar), bu yüzden üç kol eşleştirilmiş karşılaştırılmıştır.

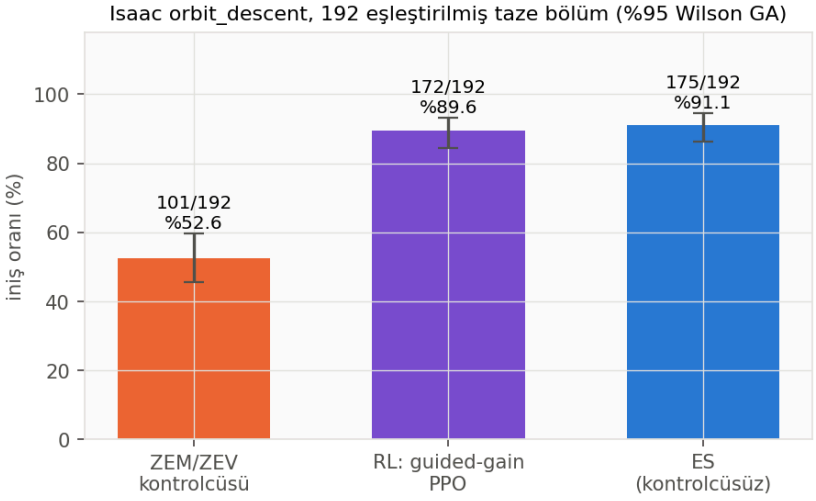
1. İkisi nasıl çalışıyor



Şekil 1. Üstte RL: kontrolcü döngüde kalır, PPO yalnızca 11 kazanç çarpanını 1 sn'de bir ayarlar. Altta ES: hiç kontrolcü yok, 84 parametreli lineer politika doğrudan gaz ve üç eksen torku verir.

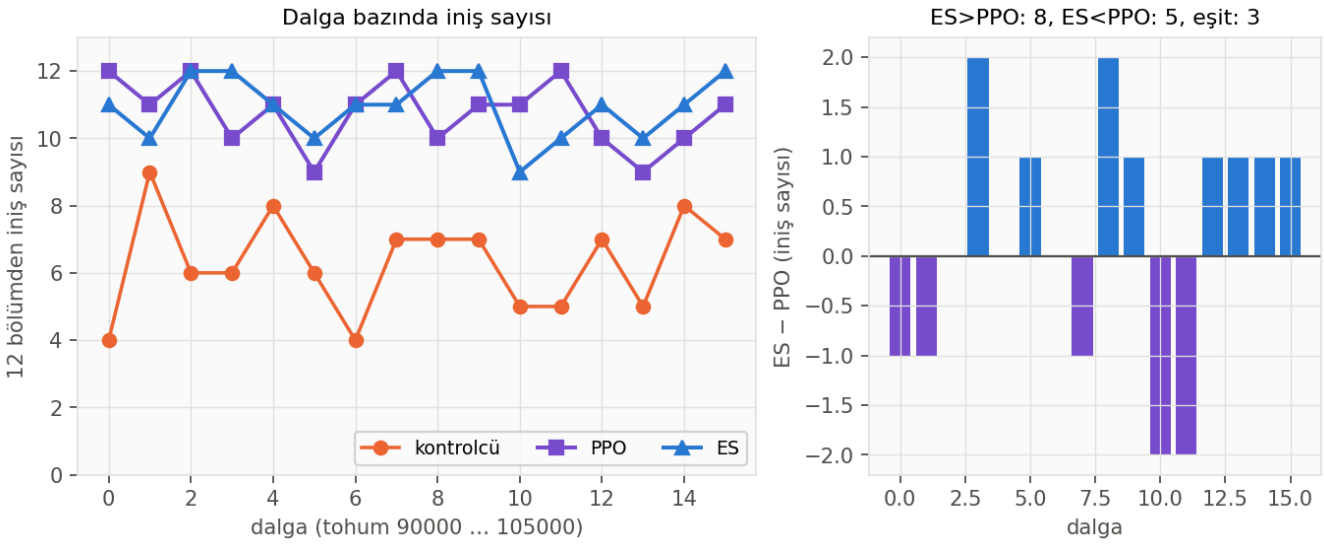
	RL: guided-gain PPO	ES (kontrolcüsüz)
Ne öğreniliyor	kontrolcünün 11 kazancının çarpanları (durumdan)	doğrudan eyleyici komutu (durumdan)
Kontrolcü döngüde mi	**Evet**: ZEM/ZEV her adım uçar; eylem 0 = kontrolcünün kendisi	**Hayır**
Eylem uzayı / frekans	11 boyut, 1 sn'de bir karar, 20 adım tutma	4 boyut (gaz, pitch, roll, yaw), 20 Hz
Politika / parametre	64×64 tanh MLP, 23→11 (≈6.4 bin ağırlık, + değer ağı)	lineer, 20→4 (84 parametre)
Gözlem	20 ham + 3 ek (t_go, final-mi: kontrolcünün iç durumundan; v_xy)	20 (çalışan ort./std normalize); slot 16–19 rehber alanı
Ödül / uygunluk	sadece sonuç: +5 iniş, 0 başarısız temas, −3 zaman aşımı/devrilme (`reward_scale=0`)	sadece sonuç, derecelendirilmiş: temas şiddeti (cap 480), zaman aşımı −480
Optimizer	PPO (γ=0.995, λ=0.99, lr 1e-4, 8 ortam)	OpenAI-ES (48 antitetik çift, sıralama şekillendirme, Adam)
Eğitim backend'i	Isaac ortamı (`IsaacLanderVecEnv`), orbit_descent doğrudan	analitik backend, 5 basamaklı müfredat (warm-start); Isaac'te sıfır-atış
Doğrulama	Isaac, 192 eşleştirilmiş, tohum 90000–105000	aynı

2. Sonuçlar (Isaac, 192 eşleştirilmiş taze bölüm)

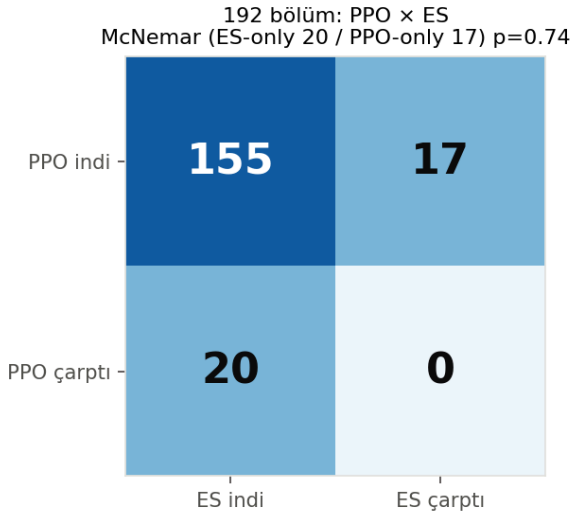


Şekil 2. İniş oranları ve %95 Wilson güven aralıkları. Aralıklar büyük ölçüde örtüşüyor.

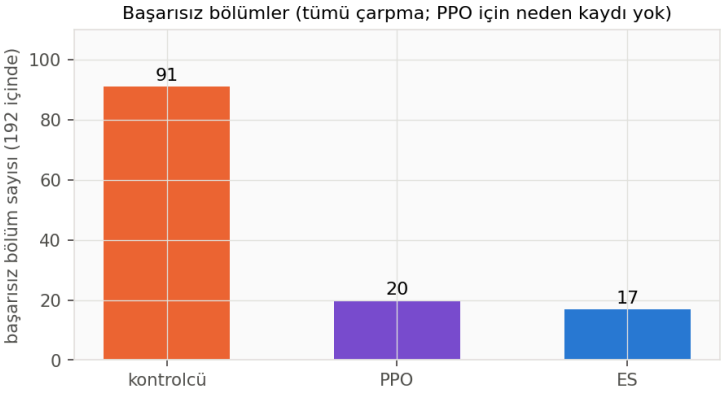
karşılaştırma	sadece ilki indi	sadece ikincisi indi	McNemar p	fark, %95 bootstrap (puan)
kontrolcü → PPO	1	72	1.6e-20	+37.0 [+29.7, +44.3]
kontrolcü → ES	5	79	3.4e-18	+38.5 [+32.3, +44.3]
PPO → ES	17	20	**0.74**	+1.6 [-3.6, +6.2]



Şekil 3. Dalga bazında iniş sayıları ve ES − PPO farkı. Fark küçük ve işaret değiştiriyor; tek bir yönde sistematik üstünlük görülmüyor (16 dalgada 8 / 5 / 3).

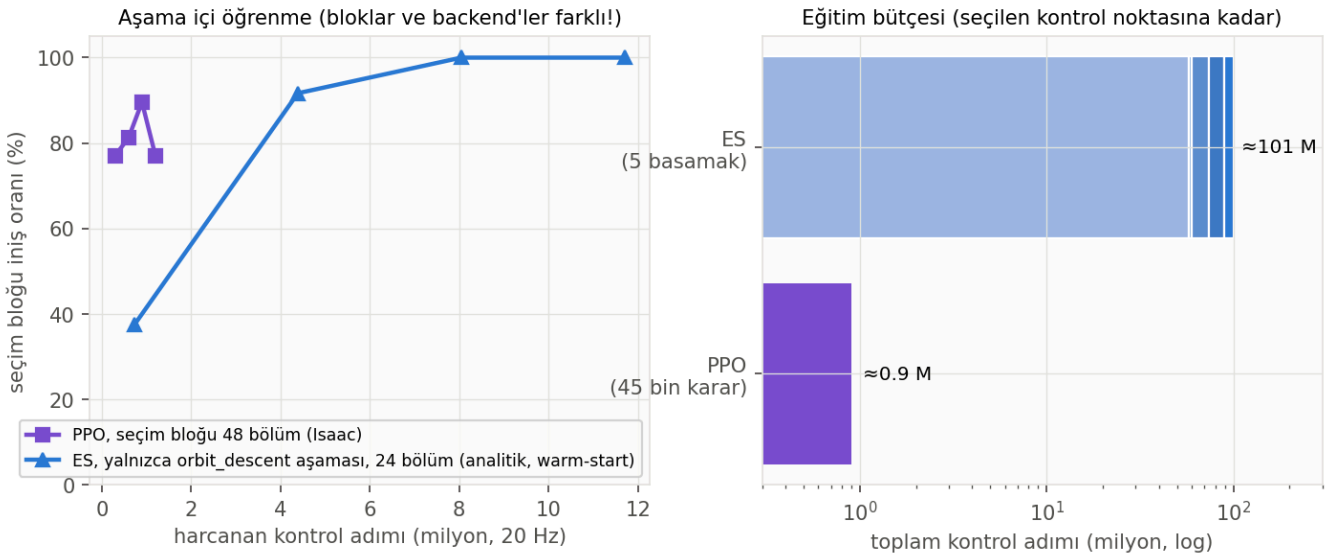


Şekil 4. PPO ve ES'in bölüm bazında örtüşmesi. İkisinin de çarptığı bölüm **0**: PPO'nun 20 hatasını ES, ES'in 17 hatasını PPO çözüyor. Yani hatalar farklı bölümlerde; bu iki yöntemin aynı zor bölümlerde takılmadığını gösterir, ama bir "topluluk" sonucu olarak raporlanmadı.



Şekil 5. Başarısız bölümler. ES: {'crash': 17, 'landed': 175}; kontrolcü: {'crash': 91, 'landed': 101}. PPO doğrulama dosyası sonlanma nedenini kaydetmiyor.

3. Örnek verimliliği ve bütçe



Şekil 6. Solda seçim bloğundaki iniş oranı, sağda toplam harcanan kontrol adımı (log ölçek). Birimler: 1 PPO kararı = 20 kontrol adımı (1 sn). ES için bölüm sayıları eğri dosyalarından, bölüm süresi ise doğrulamadaki iniş süresinden alınmış tahmindir.

	PPO	**ES**
Seçilen kontrol noktası	45,000 karar (8 ortam), seçim bloğu 43/48; bütçe 60,000 karar	müfredatın 5 basamağı, seçilen nesle kadar toplam 168,192 bölüm (ramp_35m 115,200, ramp_50m 4,608, ramp_100m 19,968, ramp_150m 16,128, orbit_descent 12,288)
Kontrol adımı (20 Hz)	≈ 0.90 M	≈ 101 M toplam (≈ 11.7 M yalnızca orbit_descent)
Duvar saati	4011 s toplam süreç (≈ 67 dk; SB3 eğitim parçası ≈ 4 × 15 dk + 4 değerlendirme; ≈ 17 karar/sn)	≈ 12 dk (ramp_35m) + ≈ 40 dk (4 basamak), 16 çekirdek CPU, toplam ≈ 52 dk; dosya oluşturma/değiştirme zaman damgalarından, müfredat süresi basamak başı doğrulama koşularını içerir
Donanım	1 GPU (Isaac)	16 çekirdek CPU (analitik)

Kontrol adımı bakımından ES, PPO'nun yaklaşık 112 katı simülasyon harcıyor (yalnızca son aşama için yaklaşık 13 kat; ramp_35m için bölüm süresi 25 sn bütçesinden alındığından toplam bir üst sınırdır). Buna karşılık analitik backend, Isaac ortamından çok daha hızlı; duvar saati bu yüzden iki yöntemde aynı mertebede. Bu nedenle "ES örnek açısından verimsiz, saat açısından rekabetçi" demek ölçümle uyumludur, "ES daha verimli" demek değildir.

4. Dürüst sınırlar

- **Tek tohum, tek koşu.** PPO tek tohumdu (seed 21; bu, tekrar üretilmiş koşu); ES de tek tohum. Tekrarlanabilirlik ölçülmedi. Geçmiş PPO koşularında tohumlar arası sonuçlar çok oynadı (handover.md §0: land_handoff'ta iki tohum %21.9 ve %31.2).
- **Çözünürlük.** 192 bölümle bu eşleştirilmiş deneyde farkın %95 yarı-genişliği yaklaşık ±6.2 puan; ES–PPO farkı (+1.6 puan) bunun çok içinde.
- **Farklı backend'ler.** PPO Isaac ortamında, ES analitik ortamda eğitildi ve Isaac'te sıfır-atış doğrulandı. Seçim blokları farklı (PPO: tohum 7000, 48 bölüm, Isaac; ES: tohum 150000+, 24

bölüm, analitik); eğri karşılaştırması yalnızca yön verir.

- **Seçim yanlılığı.** İki yöntemde de kontrol noktası kendi seçim bloğunda seçildi; sayılar taze doğrulama bloğundandır. PPO'nun 45 bin kararlık noktası dört değerlendirmeden (15k/30k/45k/60k: %77, %81, %90, %77) en iyisi; ara değerler gürültülü.
- **PPO kontrolcüye ihtiyaç duyar** ve kontrolcünün iç durumunu (t_go, final-mi) gözlem olarak görür; ES kontrolcüsüzdür ama gözlemindeki rehber slotlar (16–19) ödül ağırlıklarından hesaplanır. İkisi de rehber bilgiyi girdi olarak kullanıyor.
- **ES eğitimi kısa kesildi.** orbit_descent aşaması 16 nesilde durdu (24 bölümlük seçim bloğu iki kez ≥%97); daha uzun eğitim denenmedi.
- **Ödül farkı.** PPO ödülü ikili sonuç (iniş/başarısız), ES uygunluğu derecelendirilmiş şiddet; "aynı hedef" değil, "aynı sonuç ölçütü" (landed_safely).

5. Veri kaynakları

PPO doğrulama	`~/lunarsim_artifacts/gg_isaac_orbit_v4_seed21_repro_validation.json` (+ `.log`); eğitim: `out/gg_isaac_orbit_v4_seed21_repro.log`, `…/curve.csv`
ES doğrulama	`out/evo/isaac_orbit_val192.json`; eğitim: `out/evo/an_n1/`, `out/evo/an_ladder_*/curve.csv`, `out/evo/ladder.log`
Eşleştirme kontrolü	kontrolcü vektörleri iki dosyada özdeş, dalga tohumları özdeş